Jurnal Pendidikan Teknologi dan Kejuruan
Vol. 23, No. 2, Juli 2026
P-ISSN: 0216-3241 E-ISSN: 2541-0652

PERBANDINGAN KINERJA NAIVE BAYES DAN SVM BERBASIS SMOTE DALAM ANALISIS SENTIMEN KOMENTAR YOUTUBE MENGENAI WACANA REDENOMINASI RUPIAH

Kadek Kusuma Wardana[1)], I Gede Aris Gunadi[2)], Luh Joni Erawati Dewi [3)]
[1,2,3] Program Studi Ilmu Komputer, Pascasarjana, Universitas Pendidikan Ganesha
Email: kusuma.wardana@student.undiksha.ac.id, igedearisgunadi@undiksha.ac.id, joni.erawati@undiksha.ac.id

ABSTRAK

Redenominasi merupakan kebijakan penyederhanaan nominal mata uang tanpa mengubah nilai tukar maupun daya beli. Wacana redenominasi rupiah kembali menjadi perhatian publik setelah pemerintah dan Bank Indonesia menyampaikan kesiapan implementasinya, sehingga memunculkan beragam tanggapan masyarakat di media sosial, khususnya YouTube. Kondisi tersebut mendorong perlunya analisis sentimen untuk mengidentifikasi kecenderungan opini publik secara akurat. Penelitian ini bertujuan membandingkan kinerja Naïve Bayes dan Support Vector Machine (SVM) dalam mengklasifikasikan sentimen komentar pada kanal CNBC Indonesia, Kompas Pontianak, dan Kumparan. Ketidakseimbangan data ditangani menggunakan Synthetic Minority Over-sampling Technique (SMOTE), sedangkan ekstraksi fitur menggunakan TF-IDF. Evaluasi dilakukan menggunakan accuracy, precision, recall, F1-score, ROC AUC, pengujian overfitting, dan K-Fold Cross Validation. Hasil menunjukkan bahwa SMOTE meningkatkan performa kedua model. SVM memberikan hasil terbaik pada rasio 50:50 dengan accuracy 76,34%, precision 76,33%, recall 76,34%, F1-score 75,46%, dan ROC AUC 81,44%. Dengan demikian, SVM lebih optimal dibandingkan Naïve Bayes dalam klasifikasi sentimen terkait wacana redenominasi rupiah.

Kata kunci: Analisis Sentimen, Redenominasi,Rupiah,Naïve Bayes,SVM, SMOTE

ABSTRACT

Redenomination is a policy of simplifying the nominal value of a currency without changing the exchange rate or purchasing power. The discourse on rupiah redenomination has again become a public concern after the government and Bank Indonesia announced its readiness for implementation, resulting in various public responses on social media, particularly YouTube. This situation has prompted the need for sentiment analysis to accurately identify public opinion trends. This study aims to compare the performance of Naïve Bayes and Support Vector Machine (SVM) in classifying comment sentiment on the channels CNBC Indonesia, Kompas Pontianak, and Kumparan. Data imbalance was handled using the Synthetic Minority Oversampling Technique (SMOTE), while feature extraction used TF-IDF. Evaluation was carried out using accuracy, precision, recall, F1-score, ROC AUC, overfitting testing, and K-Fold Cross Validation. The results show that SMOTE improves the performance of both models. SVM yielded the best results at a 50:50 ratio, with an accuracy of 76.34%, a precision of 76.33%, a recall of 76.34%, an F1-score of 75.46%, and an ROC AUC of 81.44%. Thus, SVM was more optimal than Naïve Bayes in classifying sentiment related to the rupiah redenomination discourse.

Keywords : *Sentiment Analysis, Redenomination, Rupiah, Naïve Bayes, SVM, SMOTE*

1. PENDAHULUAN

Redenominasi merupakan program untuk menyederhanakan nominal mata uang tanpa mengubah nilai tukarnya. Redenominasi pada rupiah yang akan terjadi adalah mengubah nominal dari awalnya Rp.1000 menjadi Rp.1. Pemberitaan mengenai kesiapan redenominasi telah menjadi pembicaraan di masyarakat Indonesia melalui sosial media setelah Bank Indonesia menyampaikan kesiapan implementasinya, menjadi trending dalam pembahasan di beberapa sosial media terutama

pada youtube.Youtube merupakan platform video dengan jumlah pengguna mencapai 95% dari pengguna internet [1].Video dari beberapa channel youtube yang membahas mengenai redenominasi rupiah seperti CNBC Indonesia, Kompas Pontianak dan Kumparan mendapat jumlah view paling banyak dibandingkan dengan video lainnya yang dari video yang dibahas mencapai ribuan komentar dikarenakan video yang membahas mengenai wacana redenominasi dan mendapat banyak komentar di masyarakat, pemberitaan mengenai wacana redenominasi pada rapat dewan gubernur bulanan Bank Indonesia pada bulan juni 2023.

Analisis sentimen merupakan suatu metode yang digunakan untuk menilai opini atau pandangan yang disampaikan melalui teks maupun ujaran [2], kemudian mengelompokkannya ke dalam kategori sentimen, seperti positif atau negatif [3]. Analisis sentimen ini memungkinkan peneliti untuk mengidentifikasi berbagai opini yang berkembang pada platform youtube. Selain berdasarkan komentar yang telah dianalisis [4]. Berdasarkan penelitian Nurrochmah dkk, Temuan pada penelitian ini menunjukkan bahwa model yang diterapkan berhasil mencapai akurasi sebesar 88% dan dijelaskan penggunaan metode ini disesuaikan dengan kecocokan jenis data yang menggunakan data berupa teks komentar dan Naïve bayes memiliki keunggulan yang terletak pada efisiensi pengolahan data teks berukuran besar dengan komputasi yang lebih ringan [5]. Dan penelitian dari Harnelia. (2024), algoritma SVM terdapat garis pemisah yang disebut hyperplane yang digunakan sebagai pemisah data sentimen positif dan negatif. Hasil menunjukkan bahwa metode SVM berhasil mendapatkan akurasi sebesar 94% [6]. Sejalan dengan penelitian sebelumnya, penelitian ini menggunakan 2 metode klasifikasi yaitu Naïve Bayes dan Support Vector Machine. Kedua metode ini terbukti telah memberikan performa baik dalam melakukan klasifikasikan data analisis sentimen. Support vector machine dan Naïve Bayes merupakan dua metode text mining

Dalam machine learning, sering ditemukannya ketidakseimbangan data sering menjadi permasalahan karena adanya perbedaan yang sangat signifikan antara jumlah sampel pada kelas mayoritas dan kelas minoritas [7]. Pada analisis sentimen sering ditemukan data tidak seimbangnya antara data opini positif dan negatif. Algoritma pada machine learning cenderung menghasilkan model yang kurang sensitif terhadap kelas minoritas dalam kondisi data tidak seimbang, sehingga performa klasifikasi analisis sentimen dapat menjadi kurang optimal [8]. Salah satu metode yang dapat digunakan untuk mengatasi permasalahan tersebut adalah SMOTE [9].Penelitian oleh Hidayatullah & Umaidah. (2023). SMOTE dipilih karena kemampuannya dalam mengatasi ketidak seimbangan dataset, SMOTE secara spesifik mengatasi hal ini dengan menciptakan data tambahan untuk kelompok minoritas, Dan untuk hasil secara keseluruhan akurasi sebesar 87.20% [10]. Modifikasi ini memungkinkan penyesuaian yang lebih spesifik untuk meningkatkan akurasi dan efektivitas dalam menangani data yang tidak seimbang.

Beberapa penelitian sebelumnya telah menganalisis sentimen, diantaranya adalah Huwaida dkk. (2024) Menggunakan SMOTE untuk menyeimbangkan jumlah data pada kelas minoritas (negatif dan positif) di data latih untuk meningkatkan akurasi klasifikasi Naive Bayes 76,01% [11], selanjutnya ada Penelitian oleh Huda dkk. (2023) beberapa algoritma digunakan sebagai perbandingan, antara lain Logistic Regression, Multinomial Naïve Bayes,Decision Tree, K-Nearest Neighbors, Random Forest, dan Support Vector Machine. Hasil pengujian model menunjukkan algoritma Support Vector Machine memiliki performa terbaik dengan accuracy sebesar 69%, kemudian menggunakan SMOTE untuk seimbangkan data mendapatkan meningkatkan hasil akurasi sebesar 13%, mencapai akurasi sebesar 82% [12]. Selanjutnya Penelitian oleh Rahayu dkk. (2024) menggunakan SMOTE untuk balancing data dikarenakan adanya ketidak seimbangan pada untuk pengujian menggunakan confusion matrix dan K-Fold untuk validasi data Hasil yang didapatkan menunjukkan algoritma NBC memiliki akurasi tertinggi dibandingkan dengan KNN. Hasil akurasinya yaitu 74%, precision 74.6%, recall 74% dan f1-score 73.9% [13].

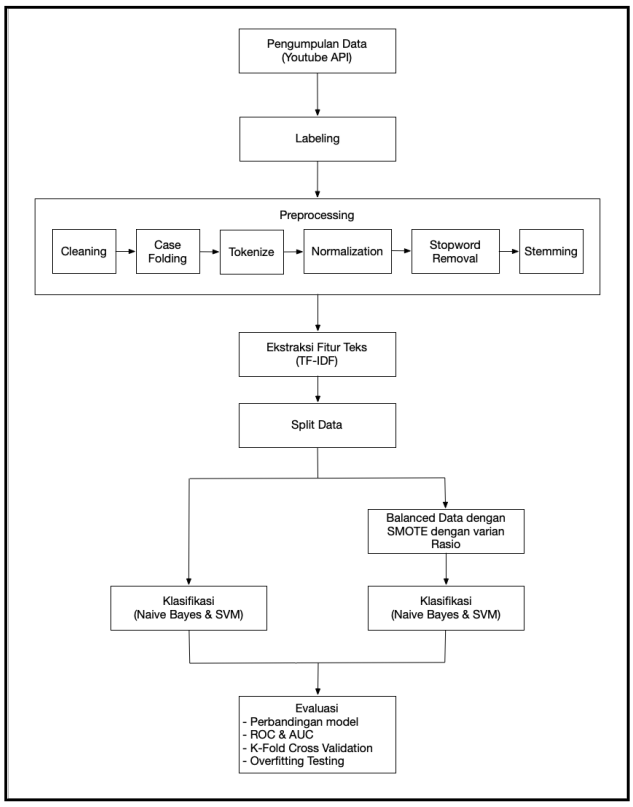
Beberapa penelitian sebelumnya telah menunjukkan bahwa penerapan SMOTE mampu meningkatkan performa klasifikasi pada data yang tidak seimbang. Namun, sebagian besar penelitian tersebut hanya menerapkan satu skenario penyeimbangan data untuk meningkatkan kinerja model dan belum mengevaluasi pengaruh variasi rasio SMOTE terhadap performa klasifikasi. Selain itu, penelitian yang membandingkan algoritma Naïve Bayes dan Support Vector Machine pada berbagai rasio SMOTE dalam analisis sentimen komentar YouTube mengenai wacana redenominasi rupiah masih terbatas. Oleh karena itu, diperlukan kajian yang tidak hanya membandingkan performa kedua algoritma, tetapi juga menganalisis bagaimana perubahan rasio SMOTE memengaruhi hasil klasifikasi sehingga dapat diperoleh rasio penyeimbangan data yang paling efektif. Sebagai pembaruan dari penelitian sebelumnya, penelitian ini mengevaluasi tujuh variasi rasio SMOTE serta melengkapi evaluasi model dengan pengujian overfitting,untuk memperoleh gambaran yang lebih komprehensif mengenai performa dan kemampuan generalisasi algoritma Naïve Bayes maupun Support Vector Machine.

Pada penelitian ini opini atau tanggapan masyarakat yang ada pada komentar youtube dataset untuk analisis sentimen. Opini masyarakat yang ada pada komentar dari video di situs web YouTube dengan domain wacana redenominasi. Terdapat 3 channel dengan view besar yang akan dianalisis komentar videonya yaitu CNBC Indonesia,Kompas Pontianak dan Kumparan. Setelah itu akan dilanjutkan dengan pelabelan dengan menggunakan ahli untuk validator label dari data komentar untuk menentukan pelabelan opini termasuk positif, atau negatif.

Penelitian ini menggunakan Term Frequency–Inverse Document Frequency (TF-IDF) untuk mengekstraksi fitur dan mengubah data teks menjadi representasi numerik. Selanjutnya, penelitian membandingkan performa algoritma Naïve Bayes dan Support Vector Machine pada skenario tanpa SMOTE dan dengan SMOTE. Berbeda dengan penelitian sebelumnya yang umumnya hanya menggunakan satu rasio penyeimbangan data, penelitian ini mengevaluasi beberapa variasi rasio SMOTE, yaitu 20:80, 30:70, 40:60, 50:50, 60:40, 70:30, dan 80:20, untuk menganalisis pengaruh setiap rasio terhadap performa klasifikasi. Evaluasi model dilakukan menggunakan Confusion Matrix melalui metrik accuracy, precision, recall, dan F1-score, serta ROC AUC, pengujian overfitting, dan K-Fold Cross Validation. Hasil penelitian diharapkan dapat memberikan referensi mengenai rasio SMOTE yang paling efektif dalam meningkatkan performa klasifikasi sentimen pada wacana redenominasi rupiah serta memperkaya kajian analisis sentimen di bidang *text mining*.

2. METODE

Metode penelitian disusun untuk menghasilkan model klasifikasi analisis sentiment wacana redenominasi rupiah. Tahapan penelitian ditunjukkan pada Gambar 1 dan dijabarkan melalui beberapa subbagian berikut.



Gambar 1 Tahapan penelitian

A. Studi Literatur

Studi literatur dilakukan dengan menelaah penelitian terkait analisis sentimen, machine learning, Natural Language Processing. Hasil studi literatur digunakan untuk menentukan pendekatan penelitian, dan alur pengembangan.

B. Pengumpulan data

Pengumpulan data pada penelitian diperoleh dengan menggunakan API dari Youtube. Dengan bahasa pemrograman python [14]. Data yang diambil dari video pemberitaan mengenai redenominasi

rupiah dari 3 channel youtube CNBC Indonesia,KompasTV Pontianak dan Kumparan dengan topik Redenominasi rupiah dipilih berdasarkan 3 video youtube dengan views tertinggi yang membahas redenominasi rupiah pencarian menggunakan kata kunci pencarian “redenominasi rupiah” pada periode bulan juni sampai juli 2023.

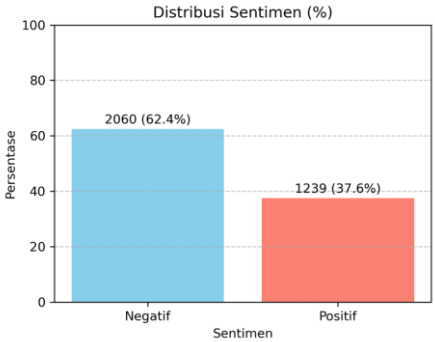
C. Labelling

Pelabelan dilakukan secara manual dengan melibatkan tiga orang ahli bahasa. Proses pelabelan dilakukan secara independen terhadap 3.421 data komentar. Untuk mengukur tingkat kesepakatan antarpenilai (inter-rater agreement), digunakan Fleiss' Kappa, yaitu metode statistik yang digunakan untuk mengukur tingkat kesepakatan lebih dari dua penilai dalam memberikan kategori pada data yang sama. Perhitungan Fleiss' Kappa dilakukan menggunakan bahasa pemrograman Python dengan library statsmodels.stats.inter_rater melalui fungsi fleiss_kappa. Nilai Fleiss' Kappa berada pada rentang -1 hingga 1, di mana nilai yang semakin mendekati 1 menunjukkan tingkat kesepakatan yang semakin tinggi. Berdasarkan interpretasi Landis dan Koch, nilai 0,81–1,00 termasuk kategori almost perfect agreement. Hasil perhitungan pada penelitian ini memperoleh nilai Fleiss' Kappa sebesar 0,9884, yang menunjukkan bahwa ketiga ahli memiliki tingkat kesepakatan yang hampir sempurna dalam proses pelabelan.

Penentuan label akhir menggunakan metode majority voting, yaitu apabila minimal dua dari tiga ahli memberikan label sentimen yang sama (misalnya positif atau negatif), maka label tersebut ditetapkan sebagai label akhir. Pendekatan ini dipilih untuk mengurangi subjektivitas individu dan meningkatkan reliabilitas hasil pelabelan. Komentar yang berada di luar ruang lingkup penelitian diberi label hapus. Komentar dengan label tersebut tidak digunakan dalam proses analisis sehingga dikeluarkan dari dataset. Tahapan pelabelan menghasilkan 2.060 komentar berlabel negatif dan 1.239 komentar berlabel positif, sehingga jumlah data yang digunakan dalam proses analisis sebanyak 3.299 komentar. Persentase keberhasilan pelabelan dapat dilihat pada Gambar 2, sedangkan contoh hasil pelabelan disajikan pada Tabel 1.

Tabel 1. Dataset pelabelan ahli bahasa

Comment	Ahli 1	Ahli 2	Ahli 3	Hasil
Klau ingin cpat maju,hrs cpat dilaksanakan,biar sama negara2 maju,karena ini akan mempermudah	Negatif	Negatif	Positif	Negatif
Setuju sja asalkan desainnya tetap sma biar Masyarakat tdk bingung	Positif	Positif	Negatif	Positif
Kasian uang yg jadi korban , sepatutnya yg dipotong para mafia	Negatif	Negatif	Negatif	Negatif



Gambar 2. Distribusi Sentimen Setelah Labeling

D. Preprocessing

Tahapan preprocessing meliputi cleansing untuk membersihkan atau menghapus noise pada data komentar, case folding untuk mengubah huruf pada data menjadi huruf kecil(lower case), tokenize untuk memecah kalimat yang ada pada data teks menjadi potongan karakter atau kata, normalization untuk mengubah kata yang tidak baku menjadi kata baku yang sesuai dengan KBBI, Stopword removal untuk menghapus kata-kata yang kurang memiliki makna seperti “yang”,”di”,”ke”, stemming untuk merubah kata dasar yang telah diproses dari stopword removal seperti dengan menghilangkan kata-kata imbuhan seperti “me-kan”, dimodifikasi atau menghapus elemen data berupa tekstual yang tidak

diperlukan dalam proses data mining berikutnya [15]. Preprocessing terdiri dari beberapa tahapan seperti berikut.

1. Cleansing

   Cleansing merupakan tahap pembersihan data dengan menghapus karakter yang tidak diperlukan, seperti tanda baca, angka, kata duplikat, serta spasi berlebih pada awal dan akhir teks[16]. Selain itu, kata-kata yang memiliki panjang kurang dari tiga huruf juga dihapus untuk mengurangi noise pada data. Proses ini bertujuan menghasilkan data teks yang lebih bersih sehingga siap digunakan pada tahapan preprocessing berikutnya.
2. Case Folding

   Case folding merupakan tahap mengubah seluruh huruf pada teks menjadi huruf kecil (lowercase) [17]. Proses ini bertujuan untuk menyeragamkan penulisan kata sehingga menghindari perbedaan akibat penggunaan huruf kapital. Dengan demikian, data menjadi lebih konsisten dan siap digunakan sebagai masukan pada proses klasifikasi.
3. Tokenize

   Tokenizing atau tokenisasi merupakan proses memecah kalimat pada data teks menjadi token-token berupa kata [18]. Tahap ini bertujuan untuk mengubah teks menjadi unit-unit yang lebih kecil sehingga lebih mudah diproses pada tahapan analisis selanjutnya. Hasil tokenisasi kemudian digunakan sebagai masukan pada proses preprocessing berikutnya.
4. Normalization

   Normalisasi merupakan tahapan mengubah kata-kata tidak baku, termasuk singkatan dan istilah dalam data teks, menjadi bentuk baku yang sesuai dengan kaidah Kamus Besar Bahasa Indonesia (KBBI). Proses ini bertujuan untuk menyeragamkan variasi penulisan kata sehingga meningkatkan kualitas data. Dengan demikian, representasi kata menjadi lebih konsisten pada tahap analisis selanjutnya.
5. Stopword Removal

Stopword removal merupakan tahap menghapus kata-kata yang memiliki makna rendah atau tidak memberikan kontribusi signifikan terhadap proses klasifikasi, seperti "yang", "di", "ke", dan kata umum lainnya[19]. Proses ini dilakukan setelah tahap tokenizing untuk mengurangi jumlah kata yang tidak relevan. Dengan demikian, data yang digunakan pada proses analisis menjadi lebih fokus pada kata-kata yang memiliki informasi penting.

6. Stemming

   Stemming adalah proses merubah kata dasar yang telah diproses dari stopword removal seperti dengan menghilangkan kata-kata imbuhan seperti “me-kan” [19]. Proses ini dilakukan dengan menghapus imbuhan, seperti awalan, akhiran, sisipan, atau konfiks, sehingga diperoleh bentuk dasar dari suatu kata. Dengan demikian, kata-kata yang memiliki makna sama tetapi bentuk berbeda dapat direpresentasikan secara konsisten dalam proses klasifikasi.

E. Ekstraksi Fitur

Ekstraksi fitur teks adalah teknik untuk merangkum data teks ke dalam ke dalam kumpulan fitur yang lebih ringkas. Term Frequency-Inverse Document Frequency (TF-IDF) merupakan metode yang menilai pentingnya suatu kata dalam dokumen dengan memberikan bobot berdasarkan seberapa sering kata tersebut muncul dalam dokumen tertentu dibandingkan dengan keseluruhan kumpulan dokumen. Dalam Implementasi TF-IDF dapat dilakukan menggunakan pustaka python yaitu sklearn.feature_extraction.text .

F. Split Data

Tahapan Split data merupakan tahapan membagi dataset menjadi data latih (training data) dan data uji (testing data) [20]. Pada penelitian ini menggunakan library pada pemrograman python yaitu sklearn.model_selection,train_test_split. Data yang sudah dibagi dari jumlah data 3252 menjadi data latih sebanyak 2601 untuk sentimen positif menjadi 975 kemudian untuk negatif 1626 dan untuk data uji sebanyak 651 untuk sentimen positif jumlahnya 251, negatif 400.

G. Balancing Data

SMOTE adalah teknik oversampling yang dirancang untuk mengatasi masalah data yang tidak seimbang. Teknik ini bekerja dengan membuat data sintetis pada kelas minoritas berdasarkan hubungan jarak antar sampel yang memiliki karakteristik serupa. Dengan demikian, distribusi kelas menjadi lebih proporsional dan kemampuan model dalam mengidentifikasi kelas yang jarang muncul dapat meningkat[21].Tahapan balancing data dilakukan untuk mengatasi ketidakseimbangan jumlah data pada masing-masing kelas sentimen. Setelah data teks melalui proses preprocessing dan

ditransformasikan ke dalam representasi numerik menggunakan TF-IDF, dataset dibagi menjadi data latih (training set) dan data uji (testing set). Pada skenario yang menggunakan SMOTE, proses oversampling hanya diterapkan pada data latih hasil transformasi TF-IDF beserta label kelasnya, sedangkan data uji tidak mengalami proses resampling. Pendekatan ini bertujuan untuk menghindari data leakage sehingga evaluasi performa model dilakukan menggunakan data uji yang tetap merepresentasikan distribusi data asli.

SMOTE menghasilkan sampel sintetis berdasarkan representasi numerik hasil pembobotan TF-IDF pada kelas minoritas. Dengan demikian, data sintetis yang dihasilkan bukan berupa teks baru, melainkan vektor fitur numerik yang memiliki karakteristik serupa dengan data pada kelas minoritas. Pada penelitian ini, kelas sentimen negatif merupakan kelas mayoritas, sedangkan kelas sentimen positif merupakan kelas minoritas. Oleh karena itu, proses oversampling dilakukan pada kelas sentimen positif hingga mencapai rasio yang telah ditentukan terhadap kelas sentimen negatif. Selain menggunakan rasio penyeimbangan 50:50, penelitian ini juga mengevaluasi beberapa variasi rasio SMOTE, yaitu 20:80, 30:70, 40:60, 60:40, 70:30, dan 80:20. Menggunakan program python dengan library imblearn.over_sampling SMOTE menunjukkan data mirip seperti hasil TF-IDF dimana setiap kata pada data sintetis memiliki bobot.Jumlah data pada varian rasio dapat dilihat pada tabel 2.

Tabel 2. Hasil penerapan SMOTE dengan varian rasio

No	Rasio	Positif	Negatif
1	Tanpa SMOTE	975	1626
2	SMOTE 50:50	1626	1626
3	SMOTE 20:80	3000	12000
4	SMOTE 30:70	3000	7000
5	SMOTE 40:60	4500	6750
6	SMOTE 60:40	6750	4500
7	SMOTE 70:30	7000	3000
8	SMOTE 80:20	12000	3000

H. Model Klasifikasi

Pada tahap klasifikasi, model diterapkan pada data yang telah melalui proses ekstraksi fitur menggunakan TF-IDF untuk mengelompokkan setiap data ke dalam kategori sentimen yang telah ditentukan. Proses klasifikasi bertujuan untuk memprediksi label sentimen berdasarkan pola yang dipelajari dari data latih. Algoritma klasifikasi yang digunakan dalam penelitian ini dijelaskan sebagai berikut.

1. Naive Bayes

Naive Bayes adalah metode yang melakukan prediksi terhadap peluang kejadian di masa depan menggunakan informasi atau pengalaman yang telah terjadi sebelumnya [20]. Algoritma ini menggunakan pendekatan probabilistik dengan menerapkan Teorema Bayes dalam proses klasifikasi data. Karakteristik utama dari metode Naïve Bayes Classifier adalah adanya asumsi independensi yang kuat (naif), yaitu setiap fitur atau kondisi dianggap tidak saling bergantung satu sama lain dalam proses klasifikasi [22].

2. SVM

Support Vector Machine adalah salah satu pendekatan untuk melakukan klasifikasi menggunakan pembelajaran mesin(Machine Learning) adalah dengan memprediksi kelas dari data baru berdasarkan model yang telah dilatih dengan data sebelumnya. Teknik ini efektif dalam bekerja dengan dataset berdimensi tinggi, menggunakan trik kernel untuk memetakan data ke ruang fitur yang lebih tinggi dan memungkinkan pemisahan yang lebih baik [23]. Algoritma ini sering diterapkan pada dataset yang besar, khususnya data yang berasal dari platform online, serta menjadi salah satu metode yang populer dalam bidang klasifikasi teks karena kemampuannya menghasilkan performa yang baik [24]

I. Evaluasi Hasil

Pada tahap ini, adalah tahapan akhir dari penelitian analisis sentimen yang bertujuan untuk melakukan perbandingan hasil dari kinerja dan performa dari masing-masing metode klasifikasi yang dapat dilihat dari beberapa pengujian :

a. Perbandingan Performa Algoritma

Confusion matrix adalah representasi tabel yang terdiri atas empat kombinasi antara nilai prediksi dan nilai aktual, yang digunakan untuk untuk melihat seberapa baik kinerja klasifikasi [25]. Pada

confusion matrix akan mendapatkan hasil *accuracy,precision,recall* dan *F1-Score* dari hasil klasifikasi sebelumnya. Dari setiap algoritma akan dibandingkan hasil akurasi datanya berdasarkan *confusion matrix*. Dengan demikian, kualitas hasil klasifikasi dapat dinilai secara lebih komprehensif [26]. Bahasa pemrograman yang digunakan adalah python dan pada model klasifikasi pada Naive Bayes menggunakan MultinomialNB dan untuk SVM menggunakan SVC yang menggunakan kernel rbf , confusion matrix menggunakan library sklearn.metrics dari confusin_matrix pada classification report menggunakan library sklearn.metrics dari classification_report,accuracy_score, precision_score, recall_score, f1_score untuk mengetahui nilai dari accuracy,recall,precision dan F1-score.

b. K-Fold Cross Validation
K-Fold Cross Validation adalah salah satu Teknik untuk validasi model dalam machine learning. Tujuan untuk menilai untuk kinerja dari metode algoritma membagi sampel data secara acak dan mengelompokkan data sesuai dengan nilai yang diinginkan yang biasanya di simbolkan dengan K [27]. pada pengujian menggunakan 5 fold untuk masing-masing model dan menggunakan bahasa pemrograman python yang dibantu dengan library sklearn.model_selection StratifiedKFold.

c. AUC
AUC(Area under Curve) merupakan salah satu metrik evaluasi yang digunakan untuk menilai performa model klasifikasi dalam membedakan kelas positif dan negatif. Rentang nilai AUC berada antara 0 hingga 1, di mana semakin mendekati angka 1 berarti kemampuan model dalam melakukan prediksi semakin baik [28]. Pada pengujian menggunakan bahasa pemrograman python dan dibantu dengan library python sklearn.metrics dengan import roc_auc_score dan roc_curve

d. Pengujian Overfitting.
Salah satu permasalahan dalam pengembangan model *machine learning* adalah overfitting, yaitu kondisi ketika model memiliki performa sangat baik pada data pelatihan (training), namun buruk pada data pengujian (testing). Overfitting menunjukkan bahwa model terlalu menyesuaikan diri terhadap pola spesifik pada data pelatihan, sehingga gagal melakukan generalisasi terhadap data baru. Pada pengujian menggunakan bahasa pemrograman python dapat menggunakan library sklearn.metrics dengan import accuracy_score. Yang nantinya akan accuracy score dari data training dan data test akan dilihat selisihnya jika selisih nilai lebih dari 10% dapat dinyatakan model tersebut overfitting.

3. HASIL DAN PEMBAHASAN

Setelah tahapan ekstraksi fitur(TF-IDF) telah selesai dilakukan karena diperlukannya mengubah teks menjadi representasi numerik yang dapat dipahami algoritma machine learning.

Analisis metode dilakukan dengan menggunakan metode confusion matrix untuk menentukan nilai accuracy,recall,precision dan f1-score dan dari keseluruhan data dengan menggunakan 4 model klasifikasi. Hasil perbandingan klasifikasi dilakukan untuk mengetahui perbandingan performa dari model yang telah dibuat dengan Naive Bayes dan SVM kedua metode ini digunakan untuk klasifikasi dari berbagai data yang telah dilakukan proses penyeimbangan data dengan SMOTE berbagai varian rasio (50:50, 20:80, 30:70, 40:60, 60:40, 70:30, dan 80:20) dan data tanpa penyeimbangan, untuk mengetahui performa terbaik dari masing-masing rasio persebaran data sentimen positif dan negatif.

1. Naïve Bayes

Pada proses klasifikasi menggunakan algoritma Naïve Bayes, dilakukan dua skenario pengujian, yaitu pada data sebelum dan sesudah dilakukan penyeimbangan menggunakan metode SMOTE. Penyeimbangan data dilakukan dengan variasi rasio 50:50, 20:80, 30:70, 40:60, 60:40, 70:30, dan 80:20 untuk menganalisis pengaruh masing-masing rasio terhadap kinerja model klasifikasi. Nilai performa model pada setiap skenario dievaluasi menggunakan metrik accuracy, precision, recall, dan F1-score, sedangkan hasil pengujian secara keseluruhan ditampilkan pada Tabel 3.

Tabel 3. Hasil performa Naive Bayes

No	Rasio	Accuracy	Precision	Recall	F1-Score
1	Tanpa SMOTE	70.66%	72.53%	70.66%	67.04%
2	SMOTE 50:50	72.35%	73.86%	72.35%	72.68%
3	SMOTE 20:80	65.13%	65.21%	65.13%	59.06%
4	SMOTE 30:70	69.43%	70.18%	69.43%	66.02%
5	SMOTE 40:60	72.96%	72.49%	72.96%	72.23%
6	SMOTE 60:40	68.51%	73.05%	68.51%	68.84%
7	SMOTE 70:30	62.67%	73.43%	62.67%	61.96%
8	SMOTE 80:20	57.14%	71.99%	57.14%	54.93%

2. SVM

Pada proses klasifikasi menggunakan algoritma Support Vector Machine (SVM), dilakukan dua skenario pengujian, yaitu pada data sebelum dan sesudah dilakukan penyeimbangan menggunakan metode SMOTE. Penyeimbangan data dilakukan dengan variasi rasio 50:50, 20:80, 30:70, 40:60, 60:40, 70:30, dan 80:20 untuk menganalisis pengaruh masing-masing rasio terhadap kinerja model klasifikasi SVM. Nilai performa model pada setiap skenario dievaluasi menggunakan metrik accuracy, precision, recall, dan F1-score, sedangkan hasil pengujian secara keseluruhan ditampilkan pada tabel 4.

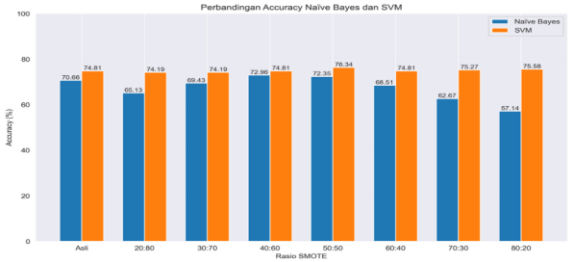
Tabel 4. Hasil performa SVM

No	Rasio	Accuracy	Precision	Recall	F1-Score
1	Tanpa SMOTE	74.81%	76.00%	74.81%	72.85%
2	SMOTE 50:50	76.34%	76.33%	76.34%	75.46%
3	SMOTE 20:80	74.19%	74.62%	74.19%	72.58%
4	SMOTE 30:70	74.19%	74.36%	74.19%	72.78%
5	SMOTE 40:60	74.81%	74.91%	74.81%	73.57%
6	SMOTE 60:40	74.81%	74.59%	74.81%	73.90%
7	SMOTE 70:30	75.27%	75.03%	75.27%	74.47%
8	SMOTE 80:20	75.58%	75.30%	75.58%	74.89%

3. Perbandingan Model

Perbandingan hasil secara keseluruhan menunjukkan bahwa model Support Vector Machine (SVM) memiliki performa yang lebih baik dibandingkan Naïve Bayes, baik dari aspek nilai evaluasi maupun konsistensi performa pada berbagai variasi rasio SMOTE. Performa terbaik SVM diperoleh pada rasio 50:50 dengan nilai accuracy sebesar 76,34%, precision 76,33%, recall 76,34%, dan F1-score 75,46%. Sementara itu, performa terbaik Naïve Bayes pada rasio yang sama memperoleh accuracy 72,35%, precision 73,86%, recall 72,35%, dan F1-score 72,68%. Selain menghasilkan nilai evaluasi yang lebih tinggi, SVM juga mempertahankan performa yang relatif stabil pada rasio data yang tidak seimbang, seperti 80:20 dengan accuracy 75,58%, yang menunjukkan bahwa algoritma ini lebih mampu beradaptasi terhadap perubahan distribusi data.

Performa SVM yang lebih baik dipengaruhi oleh kemampuannya dalam membentuk hyperplane optimal yang memaksimalkan margin antar kelas, sehingga lebih efektif mengklasifikasikan data teks berdimensi tinggi hasil ekstraksi fitur TF-IDF. Sebaliknya, Naïve Bayes mengasumsikan setiap fitur bersifat independen sehingga lebih sensitif terhadap perubahan distribusi data setelah proses oversampling menggunakan SMOTE. Hasil penelitian ini sejalan dengan penelitian Huda dkk. (2023) dan Harnelia (2024) yang menunjukkan bahwa SVM memberikan performa klasifikasi lebih tinggi dibandingkan Naïve Bayes pada analisis sentimen. Selain itu, penelitian ini menunjukkan bahwa efektivitas SMOTE tidak hanya bergantung pada penerapannya, tetapi juga dipengaruhi oleh rasio penyeimbangan data yang digunakan, di mana rasio 50:50 menghasilkan performa klasifikasi terbaik untuk kedua model. Hasil perbandingan kedua model dapat dilihat pada Gambar 3.



Gambar 3. Grafik perbandingan akurasi Naïve Bayes dan SVM rasio

Sebelum dilakukan pengujian menggunakan K-Fold Cross Validation, data yang telah melalui proses preprocessing dan ekstraksi fitur menggunakan TF-IDF dibagi menjadi data latih (training set) dan data uji (testing set). Pada skenario yang menggunakan SMOTE, proses oversampling hanya diterapkan pada data latih untuk menyeimbangkan distribusi kelas, sedangkan data uji tidak mengalami resampling sehingga tetap merepresentasikan distribusi data asli. Selanjutnya, K-Fold Cross Validation diterapkan pada data latih untuk mengevaluasi konsistensi performa model pada setiap variasi rasio SMOTE.

Berdasarkan hasil pengujian menggunakan metode K-Fold Cross Validation pada model Naïve Bayes dan SVM dengan berbagai rasio SMOTE, dapat disimpulkan bahwa kedua model menunjukkan karakteristik performa yang berbeda terhadap distribusi data. Model Naïve Bayes cenderung lebih sensitif terhadap ketidakseimbangan data, di mana performa terbaik diperoleh pada rasio 50:50 dan 40:60 dengan nilai akurasi sebesar 74% pada fold ke-5, yang menunjukkan bahwa distribusi data yang seimbang mampu meningkatkan kemampuan klasifikasi model. Namun, ketika distribusi data semakin tidak seimbang, performa model mengalami penurunan yang cukup signifikan. Sebaliknya, model SVM menunjukkan performa yang lebih stabil dan konsisten pada berbagai variasi rasio SMOTE. Performa terbaik SVM juga diperoleh pada rasio 50:50 dengan nilai akurasi sebesar 75,08%, sekaligus menjadi nilai akurasi tertinggi dibandingkan seluruh skenario pengujian yang dilakukan. Selain itu, pada rasio distribusi data yang tidak seimbang, SVM tetap mampu mempertahankan tingkat akurasi yang relatif tinggi sehingga menunjukkan sifat robust dan kemampuan generalisasi yang lebih baik dibandingkan Naïve Bayes. Dengan demikian, berdasarkan hasil evaluasi yang diperoleh, model SVM dapat dinyatakan sebagai model dengan performa terbaik dalam penelitian ini terutama pada rasio 50:50 pada fold ke-5.

Salah satu permasalahan dalam pengembangan model machine learning adalah overfitting, yaitu kondisi ketika model memiliki performa yang sangat baik pada data training, tetapi mengalami penurunan performa pada data testing karena model terlalu menyesuaikan diri terhadap pola pada data pelatihan. Dalam penelitian ini, indikasi overfitting dianalisis dengan membandingkan nilai akurasi pada data training dan testing. Selisih akurasi (generalization gap) digunakan sebagai indikator kemampuan generalisasi model, di mana semakin kecil nilai selisih menunjukkan bahwa model cenderung lebih mampu mempertahankan performanya pada data yang belum pernah dilihat. Namun, perbedaan akurasi tersebut tidak digunakan sebagai satu-satunya dasar untuk menyimpulkan terjadinya overfitting, sehingga interpretasi hasil juga didukung oleh evaluasi menggunakan K-Fold Cross Validation untuk memperoleh gambaran yang lebih komprehensif mengenai stabilitas model. Perhitungan akurasi dilakukan menggunakan fungsi accuracy_score dari pustaka sklearn.metrics. Hasil pengujian ditunjukkan pada Tabel 5.

Tabel 5. Hasil Pengujian Overfitting

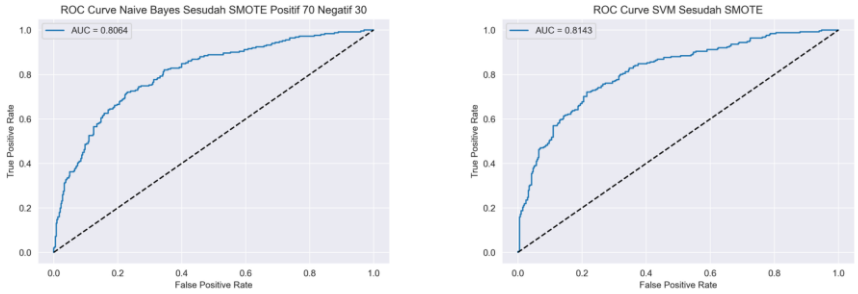
Rasio	Model	Training	Test	Gap
Tanpa SMOTE	Naive Bayes	80.62%	70.66%	9.96%
	SVM	93.43%	94.16%	-0.74%
SMOTE 50:50	Naive Bayes	86.84%	72.35%	14.49%
	SVM	96.80%	76.34%	20.46%
SMOTE 20:80	Naive Bayes	87.85%	65.13%	22.72%
	SVM	99.39%	74.19%	25.20%
SMOTE 30:70	Naive Bayes	86.23%	69.43%	16.80%
	SVM	99.29%	74.19%	25.10%
SMOTE 40:60	Naive Bayes	88.65%	72.96%	15.68%
	SVM	99.40%	74.81%	24.59%
SMOTE 60:40	Naive Bayes	68.44%	68.51%	-0.07%
	SVM	99.27%	74.81%	24.46%
SMOTE 70:30	Naive Bayes	86.09%	62.67%	23.42%
	SVM	99.19%	75.27%	23.92%
SMOTE 80:20	Naive Bayes	88.67%	57.14%	31.52%
	SVM	99.46%	75.58%	23.88%

Pada penelitian ini, indikasi overfitting dianalisis menggunakan generalization gap, yaitu selisih performa model pada data latih (training) dan data uji (testing). Pendekatan ini digunakan untuk mengevaluasi kemampuan model dalam melakukan generalisasi terhadap data yang tidak digunakan selama proses pelatihan. Semakin kecil generalization gap, semakin baik kemampuan model dalam mempertahankan performanya pada data baru.

Berdasarkan hasil pengujian pada Tabel 5, penerapan SMOTE memberikan pengaruh yang berbeda terhadap kemampuan generalisasi algoritma Naïve Bayes dan Support Vector Machine (SVM). Pada Naïve Bayes, nilai generalization gap bervariasi pada setiap rasio SMOTE. Gap terbesar diperoleh pada rasio 80:20 sebesar 31,52%, sedangkan gap terkecil terdapat pada rasio 60:40 sebesar -0,07%, yang menunjukkan bahwa performa pada data training dan testing relatif seimbang. Hal ini mengindikasikan bahwa pengaruh SMOTE terhadap Naïve Bayes bergantung pada rasio penyeimbangan data yang digunakan, sehingga tidak seluruh variasi rasio menghasilkan kemampuan generalisasi yang sama.

Sementara itu, SVM menghasilkan akurasi training yang sangat tinggi pada seluruh variasi rasio SMOTE, namun masih menunjukkan generalization gap berkisar antara 20,46% hingga 25,20% pada sebagian besar skenario. Kondisi tersebut menunjukkan bahwa peningkatan performa pada data training belum sepenuhnya diikuti oleh peningkatan yang sebanding pada data testing. Meskipun demikian, hasil K-Fold Cross Validation menunjukkan bahwa SVM tetap memberikan performa klasifikasi yang lebih tinggi dan konsisten dibandingkan Naïve Bayes. Oleh karena itu, hasil pengujian ini menunjukkan bahwa variasi rasio SMOTE memengaruhi kemampuan generalisasi kedua algoritma. Dengan demikian, pengujian overfitting pada penelitian ini tidak hanya mempertimbangkan selisih akurasi training dan testing, tetapi juga didukung oleh hasil validasi silang sehingga interpretasi terhadap kemampuan generalisasi model menjadi lebih kuat.

Pengujian Area Under Curve (AUC) dilakukan untuk menganalisis performa model klasifikasi dalam membedakan sentimen positif dan negatif. Evaluasi dilakukan menggunakan kurva Receiver Operating Characteristic (ROC) yang menggambarkan kemampuan model dalam membedakan kedua kelas pada berbagai nilai ambang keputusan (threshold). Hasil visualisasi kurva ROC disajikan pada Gambar 3, sedangkan nilai AUC masing-masing model ditampilkan pada Gambar 4 Tabel 6.



Gambar 4. Grafik ROC Naïve Bayes dan SVM dengan Nilai AUC tertinggi

Tabel 6. Hasill Pengujian AUC

Rasio	Model	AUC	Model	AUC
Tanpa SMOTE	Naive Bayes	77.78%	SVM	81.09%
SMOTE 50:50	Naive Bayes	80.46%	SVM	81.44%
SMOTE 20:80	Naive Bayes	73.32%	SVM	78.50%
SMOTE 30:70	Naive Bayes	76.47%	SVM	79.01%
SMOTE 40:60	Naive Bayes	78.25%	SVM	78.70%
SMOTE 60:40	Naive Bayes	80.32%	SVM	79.43%
SMOTE 70:30	Naive Bayes	80.64%	SVM	80.17%
SMOTE 80:20	Naive Bayes	79.59%	SVM	80.09%

Berdasarkan Gambar 4, kurva Receiver Operating Characteristic (ROC) digunakan untuk mengevaluasi kemampuan algoritma Naïve Bayes dan Support Vector Machine (SVM) dalam membedakan kelas sentimen positif dan negatif. Kurva ROC pada rasio SMOTE 50:50 dipilih sebagai representasi karena menghasilkan nilai AUC tertinggi pada kedua model. Pada gambar tersebut terlihat bahwa kurva SVM berada lebih dekat ke sudut kiri atas dibandingkan Naïve Bayes, yang menunjukkan bahwa SVM memiliki tingkat True Positive Rate yang lebih tinggi pada berbagai nilai False Positive Rate, sehingga kemampuan diskriminasi kelasnya lebih baik.

Selain itu, Naïve Bayes menunjukkan fluktuasi kurva yang lebih besar pada berbagai skenario SMOTE, yang mengindikasikan sensitivitas terhadap perubahan distribusi data hasil oversampling. Hal ini terjadi karena Naïve Bayes bergantung pada estimasi probabilitas dan asumsi independensi antar fitur, sehingga perubahan distribusi data lebih memengaruhi hasil klasifikasi. Sebaliknya, SVM

menunjukkan kurva yang lebih stabil dan konsisten karena bekerja dengan menentukan hyperplane optimal yang memaksimalkan margin antar kelas, sehingga lebih robust terhadap data tidak seimbang maupun hasil SMOTE. Dengan demikian, visualisasi ROC memperkuat hasil evaluasi bahwa SVM memiliki performa yang lebih baik dan stabil dibandingkan Naïve Bayes.

4. SIMPULAN DAN SARAN

Berdasarkan hasil pengujian menggunakan algoritma Naïve Bayes dan Support Vector Machine (SVM) dengan pembobotan TF-IDF serta penyeimbangan data menggunakan SMOTE, dapat disimpulkan bahwa penerapan SMOTE memberikan pengaruh yang berbeda terhadap masing-masing model. Pada evaluasi menggunakan accuracy, precision, recall, dan F1-score, SVM secara konsisten menunjukkan performa yang lebih baik dibandingkan Naïve Bayes pada hampir seluruh variasi rasio SMOTE. Performa terbaik diperoleh pada rasio 50:50, dengan SVM mencapai accuracy 76,34%, precision 76,33%, recall 76,34%, dan F1-score 75,46%, sedangkan Naïve Bayes memperoleh accuracy 72,35%, precision 73,86%, recall 72,35%, dan F1-score 72,68%.Hasil K-Fold Cross Validation menunjukkan bahwa SVM memiliki performa yang lebih stabil, sedangkan pengujian overfitting menunjukkan Naïve Bayes memiliki kemampuan generalisasi yang lebih baik pada kondisi tertentu, terutama pada rasio 60:40 dengan generalization gap sebesar -0,07%. Selain itu, berdasarkan pengujian AUC, SVM juga memperoleh kemampuan diskriminasi kelas yang lebih baik dengan nilai tertinggi 81,44% pada rasio 50:50, lebih tinggi dibandingkan Naïve Bayes sebesar 80,46%. Secara keseluruhan, kombinasi SVM dan SMOTE pada rasio 50:50 menjadi model terbaik karena memberikan performa klasifikasi, kestabilan, dan kemampuan diskriminasi kelas yang paling baik. Penelitian ini masih memiliki keterbatasan karena menggunakan data yang hanya berasal dari beberapa kanal YouTube dan hanya membandingkan dua algoritma klasifikasi. Oleh karena itu, penelitian selanjutnya disarankan untuk menggunakan sumber data yang lebih beragam serta membandingkan algoritma lain, seperti Random Forest, XGBoost, maupun pendekatan berbasis deep learning.

DAFTAR PUSTAKA

[1] M. Hudha, E. Supriyati, and T. Listyorini, “ANALISIS SENTIMEN PENGGUNA YOUTUBE TERHADAP TAYANGAN #MATANAJWAMENANTITERAWAN DENGAN METODE NAÏVE BAYES CLASSIFIER,” *Jurnal Informatika dan Komputer) Akreditasi KEMENRISTEKDIKTI*, vol. 5, no. 1, pp. 2614–8897, 2022, doi: 10.33387/jiko.

[2] A. T. Bisono and A. Zulherry, “Analisis Sentimen Game Genshin Impact untuk Mengetahui Reaksi dan Harapan Pemain Menggunakan Metode Naïve Bayes,” *sudo Jurnal Teknik Informatika*, vol. 4, no. 2, pp. 183–193, Aug. 2025, doi: 10.56211/sudo.v4i2.1131.

[3] D. Sabrina, A. D. Sabilla, N. Azizah, and * Korespondensi, “KOMBINASI VADER LEXICON DAN SUPPORT VECTOR MACHINE UNTUK KLASIFIKASI SENTIMEN KOMENTAR APLIKASI BLU BCA,” *INSERT: Information System and Emerging Technology Journal*, vol. 6, no. 1, 2025.

[4] N. K. T. A. Saputri, I. G. A. Gunadi, and I. M. G. Sunarya, “Analisis Sentimen Pelayanan Daring di Fakultas Teknik dan Kejuruan Universitas Pendidikan Ganesha Menggunakan Algoritma Naïve Bayes dan LSTM,” *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 4, no. 3, pp. 1120–1129, Jul. 2024, doi: 10.57152/malcom.v4i3.1336.

[5] D. S. Nurrochmah, N. Rahaningsih, R. D. Dana, and C. L. Rohmat, “Jurnal Informatika Terpadu PENERAPAN ALGORITMA NAIVE BAYES DALAM ANALISIS SENTIMEN ULASAN APLIKASI KITALULUS DI GOOGLE PLAY STORE,” *Jurnal Informatika Terpadu*, vol. 11, no. 1, pp. 1–11, 2025, doi: https://doi.org/10.54914/jit.v11i1.1544.

[6] H. Harnelia, “ANALISIS SENTIMEN REVIEW SKINCARE SKINTIFIC DENGAN ALGORITMA SUPPORT VECTOR MACHINE (SVM),” *Jurnal Informatika dan Teknik Elektro Terapan*, vol. 12, no. 2, Apr. 2024, doi: 10.23960/jitet.v12i2.4095.

[7] K. Pramayasa, I. Md, D. Maysanjaya, G. Ayu, and A. Diatri Indradewi, “Analisis Sentimen Program Mbkm Pada Media Sosial Twitter Menggunakan KNN Dan SMOTE,” 2023, doi: https://doi.org/10.31598.

[8] M. I. Putri and I. Kharisudin, “Analisis Sentimen Pengguna Aplikasi Marketplace Tokopedia Pada Situs Google Play Menggunakan Metode Support Vector Machine (SVM), Naïve Bayes, dan Logistic Regression,” *PRISMA, Prosiding Seminar Nasional Matematika*, vol. 5, pp. 759–766, 2022, doi: https://doi.org/10.35134/komtekinfo.v10i1.330.

[9] A. Agung *et al.*, “RESISTOR Journal | 32 Kombinasi Oversampling dan Undersampling dalam Menangani Class Imbalanced dan Overlapping pada Klasifikasi Data Bank Marketing,” 2024, [Online]. Available: https://s.id/jurnalresistor

[10] H. Hidayatullah and Y. Umaidah, “PENERAPAN NAÏVE BAYES DENGAN OPTIMASI INFORMATION GAIN DAN SMOTE UNTUK ANALISIS SENTIMEN PENGGUNA APLIKASI CHATGPT,” 2023. doi: https://doi.org/10.36040/jati.v7i3.6887.

[11] S. F. Huwaida, R. Kusumawati, and B. Isnaini, “Analisis Sentimen Komentar YouTube terhadap Pemindahan Ibu Kota Negara Menggunakan Metode Naïve Bayes,” *Jambura Journal of Informatics*, vol. 6, no. 1, pp. 26–39, Apr. 2024, doi: 10.37905/jji.v6i1.24718.

[12] M. N. Huda, D. A. Fauzan, M. R. S. P. Pamungkas, N. S. Ratnadewi, and A. A. Vahendra, “Optimalisasi Model Klasifikasi Sentimen Netizen Terhadap Merek Tas Luar Negeri,” *Jurnal KomtekInfo*, pp. 21–28, Mar. 2023, doi: 10.35134/komtekinfo.v10i1.360.

[13] M. Rahayu, A. Luthfiarta, L. Cahyaningrum, and A. N. Azzahra, “Pengaruh Oversampling dan Cross Validation Pada Model Machine Learning Untuk Sentimen Analisis Kebijakan Luaran Kelulusan Mahasiswa,” *JURNAL MEDIA INFORMATIKA BUDIDARMA*, vol. 8, no. 1, p. 163, Jan. 2024, doi: 10.30865/mib.v8i1.7012.

[14] P. Kumala Sari and R. Randy Suryono, “KOMPARASI ALGORITMA SUPPORT VECTOR MACHINE DAN RANDOM FOREST UNTUK ANALISIS SENTIMEN METAVERSE,” 2024. doi: https://doi.org/10.36040/mnemonic.v7i1.8977.

[15] D. A. Firdlous, R. Andrian, and S. Widodo, “Sentiment Analysis Public Twitter on 2024 Election using the Long Short Term Memory Model,” *SISTEMASI*, vol. 12, no. 1, p. 52, Jan. 2023, doi: 10.32520/stmsi.v12i1.2145.

[16] I. Nyoman Saputra Wahyu Wijaya, K. Agus Seputra, and N. Putu Novita Puspa Dewi, “FINE TUNNING MODEL INDOBERT UNTUK ANALISIS SENTIMEN BERITA PARIWISATA INDONESIA,” *Jurnal Pendidikan Teknologi dan Kejuruan*, vol. 22, no. 2, 2025, [Online]. Available: https://www.detik.com/search/searchall?query=wisata&siteid=3&sortby=time&fromdatex=01/01/2022&

[17] I. P. Dedy, W. Darmawan, G. Aditra Pradnyana, I. Bagus, and N. Pascima, “Optimasi Parameter Support Vector Machine Dengan Algoritma Genetika Untuk Analisis Sentimen Pada Media Sosial Instagram,” 2023, [Online]. Available: https://doi.org/10.31598

[18] E. R. Indriyani, P. Paradise, and M. Wibowo, “Perbandingan Metode Naïve Bayes dan Support Vector Machine Untuk Analisis Sentimen Terhadap Vaksin Astrazeneca di Twitter,” *JURNAL MEDIA INFORMATIKA BUDIDARMA*, vol. 6, no. 3, p. 1545, Jul. 2022, doi: 10.30865/mib.v6i3.4220.

[19] D. Iskandar Mulyana, N. Lutfianti, S. Tinggi Ilmu Komputer Cipta Karya Informatika, J. Radin Inten No, and J. Timur, “Analisis Sentimen Dengan Algoritma SVM Dalam Tanggapan Netizen Terhadap Berita Resesi 2023 Analysis Sentiment Using the SVM Algorithm in Netizen Responses to News of the 2023 Recession,” vol. 13, no. 1, 2023, doi: 10.30700/jst.v13i1.1339.

[20] D. Sandi and E. Utami, “Analisis Sentimen Publik Terhadap Elektabilitas Ganjar Pranowo di Tahun Politik 2024 di Twitter dengan Algoritma KNN dan Naïve Bayes,” vol. 7, no. 3, pp. 1097–1108, 2023, doi: 10.30865/mib.v7i3.6298.

[21] I. Putu *et al.*, “IMPROVING BUTTERFLY FISH IMAGE CLASSIFICATION ACCURACY USING HSV FEATURE EXTRACTION AND SMOTE-BASED DATA BALANCING PENINGKATAN AKURASI KLASIFIKASI CITRA BUTTERFLY FISH MENGGUNAKAN EKSTRAKSI FITUR HSV DAN PENYEIMBANGAN DATA BERBASIS SMOTE,” vol. 10, no. 3, 2025.

[22] I. M. A. A. D. Putra, I. M. G. Sunarya, and I. G. A. Gunadi, “Perbandingan Algoritma Naive Bayes Berbasis Feature Selection Gain Ratio dengan Naive Bayes Kovensional dalam Prediksi Komplikasi Hipertensi,” *JTIM : Jurnal Teknologi Informasi dan Multimedia*, vol. 6, no. 1, pp. 37–49, Apr. 2024, doi: 10.35746/jtim.v6i1.488.

[23] S. F. Pane, A. Owen, and C. Prianto, “Analisis Sentimen UU Omnibus Law pada Twitter Menggunakan Metode Support Vector Machine,” *Jurnal Telekomunikasi dan Komputer*, vol. 11, no. 2, p. 130, Aug. 2021, doi: 10.22441/incomtech.v11i2.10874.

[24] P. Sidik, I. Made, G. Sunarya, I. Gede, and A. Gunadi, “Comparison of Random Forest and Support Vector Machine Methods in Sentiment Analysis of Student Satisfaction Questionnaire Comments at ITB STIKOM Bali,” 2025. [Online]. Available: http://jurnal.polibatam.ac.id/index.php/JAIC

[25] D. Manuel, Y. Sinurat, D. E. Ratnawati, and D. W. Brata, “Analisis Sentimen Terhadap Kenaikan Cukai Rokok pada Media Sosial Twitter menggunakan Algoritma Naïve Bayes Classifier,” 2023. [Online]. Available: http://j-ptiik.ub.ac.id

[26] I Kadek Nicko Ananda, Ni Putu Novita Puspa Dewi, Ni Wayan Marti, and Luh Joni Erawati Dewi, “Klasifikasi Multilabel Pada Gaya Belajar Siswa Sekolah Dasar Menggunakan Algoritma

Machine Learning," *Journal of Applied Computer Science and Technology*, vol. 5, no. 2, pp. 144–154, Dec. 2024, doi: 10.52158/jacost.v5i2.940.

[27] N. Blesyova and F. Nur Hasan, "ANALISIS SENTIMEN TERHADAP BEA CUKAI MENGGUNAKAN SUPPORT VECTOR MACHINE DAN K-FOLD CROSS VALIDATION," 2024.

[28] A. Syaifudin Agil Rafsanjani *et al.*, "Sistemasi: Jurnal Sistem Informasi Analisis Sentimen Ulasan Pengguna Aplikasi KitaLulus pada Google Play Store dengan menggunakan algoritma Support Vector Machine (SVM) Sentiment Analysis of User Reviews of the KitaLulus Application on Google Play Store using the Support Vector Machine (SVM) Algorithm," Jul. 2025. doi: 10.30865/mib.v8i2.7458.